

학사학위논문

히노데 위성 데이터를 이용한 초해상화 기법 적용 및 손실함수별 성능 비교

지도교수 : 문 용 재

경희대학교 응용과학대학

우주과학과

전 강 산

초 록

좋은 품질의 관측 데이터는 심도 있는 연구로 이어지기 때문에 더 좋은 성능의 망원경을 제작하고 망원경을 탑재한 위성을 발사한다. 이 과정에서 많은 제작 비용과 시간이 소요된다. 따라서 현재의 관측 자료를 더 좋은 품질의 데이터로 변환할 수 있다면 비용과 시간 모두 절약할 수 있는 좋은 방법이라고 생각하였다. 이번 연구에서는 딥러닝(Deep Learning)을 통한 초해상화 기법을 적용하였고 현재 태양을 관측하고 있는 관측 위성 중 최고의 성능을 보이는 히노데(Hinode) 위성의 데이터를 사용하였다. 초해상화 모델(Model)과 관련된 기존의 연구에서는 다른 모델과 비교를 위해 L1 손실 함수를 주로 사용하였다. 하지만 다른 손실 함수 중 MSE(Mean Square Error) 손실 함수도 많이 사용하고 오차에 더 민감하게 작용하기 때문에 L1과 MSE 손실 함수를 사용하여 성능을 비교하였다. 해상도를 2배와 4배로 올리는 훈련 모두 손실 함수만 다르게 설정하였고 그 결과를 최대 신호대 잡음 비(Peak Signal to Noise Ratio: PSNR)와 구조적 유사 지수(structural similarity index: SSIM)와 함께 비교하였다. 그리고 초해상화 기법 적용 가능성을 확인하기 위해 가용할 수 있는 하드웨어(Hardware)에서 최대의 성능을 낼 수 있도록 기존 모델의 매개 변수들을 수정하여 연구를 진행하였고 결과를 PSNR, SSIM과 함께 시각적으로 비교하였다.

차 례

1. 서론	1
2. 기존 연구	3
2.1. 초해상화 기법 모델: RCAN	3
2.2. 위성 데이터의 초해상화 기법	4
3. 연구 방법	5
4. 연구 결과 및 분석	6
4.1. 손실함수별 성능 비교	6
4.2. 초해상화 적용 가능성	7
4.3. 결과 분석	8
5. 결론	10
참고문헌	11

1. 서론

최근 딥러닝에 대한 관심이 높아지면서 다양한 분야에서 이를 적용하려는 시도를 하고 있다. 딥러닝이란 대량의 데이터와 기술을 활용하여 심층 신경망(Deep Neural Network: DNN) 링크를 구현한다. 기본적으로 심층신경망은 인간의 두뇌와 연결성을 모방한 것으로 인간이 감각기관으로 받아들인 정보를 분석하여 결론을 도출 하듯이, 기계가 입력 값에 대해 여러 단계의 신경망을 거쳐 자율적으로 사고 및 결론을 내리는 시스템이다(그림 1). 심층 신경망은 표준 오류역전파 알고리즘으로 학습될 수 있으며 가중치는 다음 등식을 이용한 경사 하강법(Stochastic gradient descent)을 통하여 실제값과 비교하여 갱신된다.

$$\Delta w(t+1) = \Delta w(t) + \eta \frac{\partial C}{\partial w}$$

여기서, η 는 학습률(Learning rate)을 의미하며, C 는 손실함수(Loss function)를 의미한다. 손실함수는 생성된 결과 값과 실제 값 사이의 차이를 계산하는 함수로 차이를 줄이는 방향으로 훈련을 진행하며 신경 학습의 형태와 활성화함수(Activation function) 등의 요인들에 의해서 결정된다. 활성화함수는 출력값을 나타내는 함수를 말한다.




그림 1. 뇌의 신호 전달 과정을 모델링한 인공 신경망

일상생활에서 활용되고 있는 딥러닝 기술에는 음성인식 서비스부터 번역기, 자율주행 차, 의료산업, 로봇(Robot) 등이 있다. 딥러닝에서는 입력 데이터로 무엇을 쓰느냐에 따라 활용범위가 다양해진다. 입력 데이터가 이미지인 연구에서는 입력 받은 사진이 어떤 사진인지 추측하는 분류, 입력 받은 사진을 통해 새로운 사진을 만드는 생성, 저화질의 사진을 입력하면 고화질의 사진으로 출력하는 초해상화(Super-Resolution) 기법을 주로 다루고 있다. 이와 관련하여 천문학 분야에서도 합성곱 신경망(Convolutional Neural Network: CNN)을 활용하여 태양 플레어(Flare) 현상의 발생과 등급을 예보하는 것부터 cGANs(Conditional Generative Adversarial Networks)이라는 모델을 사용하여 딥러닝으로 태양 뒷면의 자기장 영상을 생성하는 등 다양하게 활용하고 있다.

대부분의 천문학에서는 관측을 통한 데이터로 주로 연구를 진행한다. 천체 관측은 크게 위성관측과 지상관측으로 나뉜다. 지상관측은 천문대에 망원경을 설치하는 것이기 때문에 설치가 쉬운 반면

기후에 영향을 받기 때문에 관측을 할 수 있는 시간이 불규칙적이다. 위성관측은 365일 관측이 가능하지만 위성을 발사해야 하므로 많은 비용이 들고 발사체에 탑재할 수 있는 무게를 고려해야 하기 때문에 기술적 한계도 존재한다. 그러므로 위성 관측에 쓰이는 위성은 한번 쏘아 올리면 짧게는 수 년, 길게는 수십년 사용되기 때문에 시간이 지나면 최신의 기술에 비해 성능이 떨어진다. 실제로, 현재 태양 관측 위성 중 가장 성능이 좋은 히노데 위성도 2006년에 발사된 위성인 만큼 히노데 위성의 기술과 현재의 기술의 차이는 존재한다. 만약 새로 발사하지 않고 현재의 관측 데이터를 보다 질 좋은 데이터로 변환할 수 있다면 경제적 이익과 더불어 다양한 분야에서 활용 가치가 높을 것이다.

기존에 진행된 초해상화 기법 연구 중 Residual Channel Attention Networks(RCAN) 모델은 좋은 성능을 보인다. 하지만 논문에서는 다른 모델들과 비교하였고 성능에 영향을 줄 수 있는 손실함수별 성능은 비교하지 않았다. 짧으면 수시간부터 길면 수일까지 걸리는 훈련과정에서 좋은 성능을 보이는 손실함수를 알게 된다면 이는 다음 훈련을 진행할 때에도 시간적으로 큰 이득이 될 것이다. 그러므로 이번 연구에서는 RCAN 모델을 사용했을 때 어떤 손실함수를 사용하는 것이 더 좋은 성능을 내는지 알아볼 것이다. 위성의 관측 이미지에 초해상화 기법을 시도하는 연구는 기존에 이루어졌다. 하지만 히노데에 비해 화질이 떨어지는 HMI(The Helioseismic and Magnetic Imager) 데이터를 사용했다는 점과 초해상화 기법을 적용한 결과물도 히노데 위성에 비해 성능이 좋지 못한 점에서 추가적인 연구가 필요하다고 생각하였다. 그러므로 이번 연구에서는 향상된 성능의 모델과 향상된 입력 데이터를 사용하여 초해상화 기법을 적용하였을 때 원본 이미지와 얼마나 유사하고 어떤 손실함수를 적용하였을 때 성능이 더 우수한 지를 알아보려 한다.

2. 기존 연구

딥러닝을 이용한 초해상화 기법에 대한 연구의 결과로 SRCNN, SRGAN, EDSR, ProGanSR, RCAN 등 다양한 방식을 사용하는 모델이 발표되고 있다. 새로운 모델이 나올 때마다 그들은 이전의 모델에서 나온 결과와 비교하여 자신들의 모델의 성능을 비교하였다. 성능은 초해상화 기법을 적용한 결과물이 원본과 얼마나 유사하느냐를 나타내는 것으로 성능을 나타내기 위해서 주로 최대 신호 대 잡음비(PSNR)와 구조적 유사 지수(SSIM)을 사용한다. 최대 신호 대 잡음비는 신호가 가질 수 있는 최대 전력에 대한 잡음의 전력을 나타낸 것으로 신호의 전력에 대한 고려 없이 평균 제곱 오차(MSE)를 이용해서 계산할 수 있으며 식은 아래와 같다. MAX_I 는 해당 영상의 최대값으로서, 해당 채널의 최댓값에서 최솟값을 빼서 구할 수 있다. 일반적으로 손실이 적을수록 높은 값을 가진다.

$$PSNR = 10 * \log_{10} \frac{MAX_I^2}{MSE}$$

구조적 유사 지수는 아래의 식을 통해 구하며 $l(x,y)$ 는 두 이미지 사이의 밝기, $c(x,y)$ 는 콘트라스트(Contrast), $s(x,y)$ 는 구조를 나타낸다. $l(x,y)$ 에서 μ 는 평균 밝기를 $c(x,y)$ 에서 σ 는 이미지의 표준편차이고 $C1, C2, C3$ 는 분모가 0이 되는 것을 방지하기 위한 상수이다. 구조적 유사 지수는 1에 가까울수록 원본이미지와 유사하다는 의미한다.

$$l(x,y) = \frac{2\mu_x\mu_y + C1}{\mu_x^2 + \mu_y^2 + C1}, \quad c(x,y) = \frac{2\sigma_x\sigma_y + C2}{\sigma_x^2 + \sigma_y^2 + C2}, \quad s(x,y) = \frac{\sigma_{xy} + C3}{\sigma_x\sigma_y + C3}$$

$$SSIM(x,y) = l(x,y)c(x,y)s(x,y)$$

2.1. 초해상화 기법 모델 : RCAN

딥러닝을 이용하여 훈련하는 과정에서 학습에 사용되는 모델에 따라 성능이 달라진다. VGGNet 연구팀의 연구에서 모델의 망의 깊이를 다르게 했을 때, 망이 깊어짐에 따라 성능이 좋아진다는 것을 밝혔다. 하지만 단순히 망을 깊게 구현했을 때 성능은 얇은 망에 비해 성능이 떨어진다는 것 또한 마이크로소프트 북경연구소의 연구에서 밝혀졌다. 이 연구팀은 이어서 망을 100층(Layer) 이상으로 구현하기 위해 잔여학습(Residual learning)을 적용하여 ResNet을 발표하였다. 잔여학습을 적용하기 위해 잔여그룹(Residual group)을 구현하였고 이전 단계의 정보를 잘 반영하기 위해 짧은 건너뛰기 연결(Short skip connection)을 추가하였다. 이로써 깊은 망도 쉽게 최적화를 할 수 있고 깊은 망을 통해 성능 또한 개선할 수 있게 되었다.

이번 연구에서 사용된 RCAN 모델은 잔여학습을 개념을 사용하면서 망을 더 깊게 구현하기 위해 잔여그룹을 여러 개 만든 뒤 잔여그룹 안에 잔여블록(Residual block)을 여러 개를 구성한 RIR 구조(Residual In Residual structure)를 사용하였다(그림 2). 잔여블록을 거칠 때는 짧은 건너뛰기 연결을 사용하고 잔여그룹들을 거칠 때는 긴 건너뛰기 연결(Long skip connection)을 사용하였다. 이런 다중 건너뛰기 연결을 사용하면 원본 이미지와 관련성이 떨어지는 저주파 정보를 무시하게 되어 망은 관련성이 높은 고주파 정보를 통해 훈련할 수 있게 된다. RCAN 모델의 다른 특징은 채널 집중 방법(Channel Attention mechanism, CA)을 사용한 것이다. 채널 집중 방법은 여러 채널 사이의 상

호연관성을 고려하여 채널별 특징들을 복원하는 것이다. RCAN 모델은 이러한 방법들을 사용하여 다른 모델보다 더 좋은 정확도를 보이며 시각적으로도 많은 증진을 이루었다.

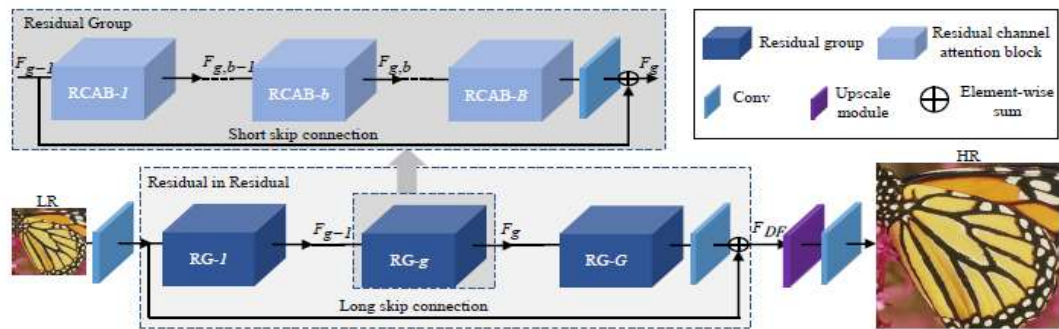


그림 2. RCAN 모델의 RIR구조 도식

2.2. 위성 데이터의 초해상화 기법 적용 사례

2010년 2월에 발사한 태양관측위성 SDO(Solar Dynamic Observatory)의 HMI는 태양표면속도지도, 태양 광구의 광범위한 파장 사진, 송수신 가능한 광구자기장 지도의 4가지 주요 데이터를 제공한다. 하지만 광구와 대양 대기의 작은 범위의 사건을 분석하기에 충분한 해상도를 가지고 있지 않다. 연구팀은 HMI 데이터를 향상시키기 위해 사진과 자력 기록(Magnetogram)에 동시에 디콘볼루션(Deconvolution)과 초해상화를 적용하는 Engance라는 새로운 방법을 제시하였다. 이를 통해 기존 HMI 직경의 두 배인 회절 제한 망원경(Diffraction-limited telescope)으로 관측한 것을 모방하는 결과를 가져올 것으로 예측하였다.

연구팀은 HMI 관측치의 부분을 입력하고 디콘볼루션 및 초해상화가 적용된 데이터를 출력하는 두 개의 완전히 깊은 콘볼루션 신경망을 기반으로 태양 활동 영역의 발생을 모의실험하여 얻은 합성 데이터를 통해 학습하였다. 연구팀은 무한한 해결과 함께 잘못 정의된 문제를 해결하기 위해 모의실험으로부터 얻은 이전의 데이터에 접근하는 신경망을 사용하였다. 이렇게 얻은 결과를 28cm 직경의 망원경 낮은 히노데 위성의 데이터와 비교하여 해상도의 향상을 이루었다(그림 3).

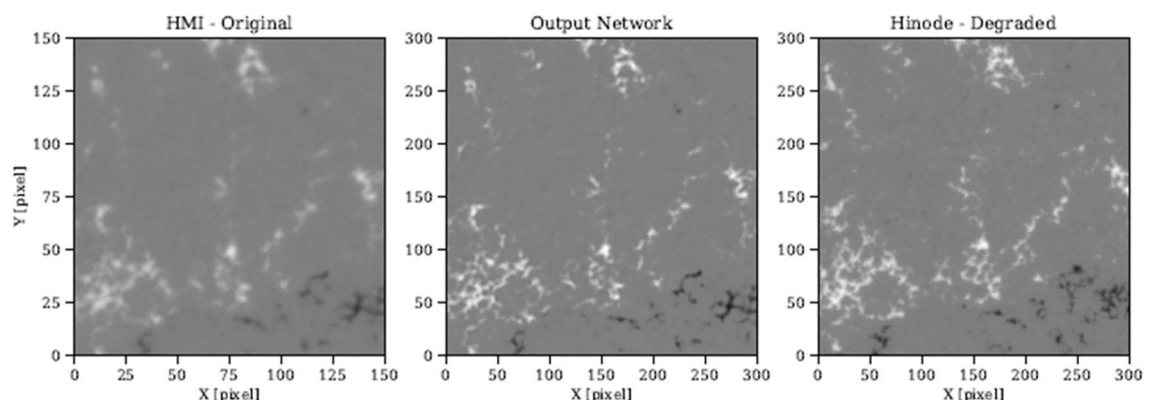


그림 3. Enhance를 적용한 결과(좌: 원본, 중: 연구 출력 사진, 우: 히노데 위성의 사진)

3. 연구방법

이번 연구에서 사용한 데이터셋(Data set)은 HINODE 위성에서 2007년 9월 7일과 8일에 관측된 찰알무늬 사진을 사용하였다. 사용된 사진의 수는 훈련에 사용된 311장, 검증에 사용된 20장 테스트(Test)에 사용된 108장이다. 비교할 데이터(data)로 968x968의 원본 사진을 사용하면 메모리(Memory)가 매우 많이 필요하고 훈련 시간도 오래 걸리므로 중앙 512x512를 잘라 사용하였다. 그리고 2배와 4배로 복원했을 때 나누어 손실함수별 성능을 비교하고 원본이미지와 얼마나 유사한 지 비교하므로 입력 데이터는 바이큐빅(Bicubic) 보간법을 사용하여 256x256과 128x128로 해상도로 낮춘 사진을 사용하였다(그림 4). 총 6가지의 경우로 나누어 훈련을 진행하였다. 경우1과 2는 2배 복원했을 때 손실함수를 비교한 것이고 경우 3과 4는 4배 복원했을 때 손실함수를 비교한 것이며 경우 5와 6은 원본 이미지와 얼마나 유사한 지 비교하기 위해 제한된 하드웨어에서 사장 좋은 성능을 낼 수 있도록 설계하여 훈련을 진행하였다(표 1). 손실함수에서 L1은 원본 사진과 출력 사진을 비교할 때 값의 차이를 절대값으로 합한 것이고 MSE는 값의 차이를 제곱하여 합한 것으로 사진은 픽셀(Pixel)값을 비교한다. 식으로 나타내면 아래와 같다.

$$L1 = \sum_{i=0}^n \sum_{j=0}^n |y_{i,j} - h(x_{i,j})|, \quad MSE = \sum_{i=0}^n \sum_{j=0}^n (y_{i,j} - h(x_{i,j}))^2$$

	손실함수	Patch size	# of residual block	Scale
경우 1	L1	100	15	2
경우 2	MSE	100	15	2
경우 3	L1	128	20	4
경우 4	MSE	128	20	4
경우 5	L1	128	20	2
경우 6	L1	192	20	4

표 1. 경우에 따른 설계 차이점




그림 4. 훈련에 사용된 입력 데이터(좌: 256x256, 우: 128x128)

4. 연구 결과

4.1. 손실함수별 성능 비교

그림 5와 그림 6은 여러 결과 중 한 데이터로 같은 데이터를 입력했을 때 결과로 512x512의 이미지이다. 왼쪽의 이미지는 L1 손실함수를, 중앙은 원본 이미지, 오른쪽은 MSE 손실함수를 나타내어 비교하였다. 그림 5는 해상도를 두 배 향상시켰을 때 결과로 시각적으로 L1 손실함수를 사용한 것이 MSE 손실함수를 사용한 것보다 좋은 결과를 보였다. 이는 PSNR과 SSIM에서도 같은 경향을 보인다. 그림 6은 해상도를 네 배 향상시켰을 때 비교한 것으로 그림 5보다 MSE 손실함수의 결과가 좋게 나왔다. 육안으로 보았을 때 L1 손실함수와 MSE 손실함수가 큰 차이를 보이지 않았지만 PSNR과 SSIM를 보았을 때 L1 손실함수에서 더 좋은 결과를 보였다. 테스트 전체의 PSNR과 SSIM의 평균은 표 2와 같이 나타났으며 전체적으로 L1 손실함수가 MSE 손실함수보다 좋은 결과를 보였다.




그림 5. 해상도를 두 배 향상시킨 경우(좌: 경우1, 중: 원본, 우: 경우2)




그림 6. 해상도를 네 배 향상시킨 경우(좌: 경우3, 중: 원본, 우: 경우4)

	경우 1(L1)	경우 2(MSE)	경우 3(L1)	경우 4(MSE)
평균 PSNR	39.56	16.70	36.98	34.97
평균 SSIM	0.9845	0.1775	0.9627	0.9557

표 2. 손실함수별 성능 비교

4.2. 초해상화 적용 가능성

그림 7은 해상도를 두 배 향상했을 때 왼쪽의 원본 이미지와 오른쪽의 결과 이미지를 비교한 것이다. 육안으로 큰 차이를 보이지 않았고 이는 PSNR과 SSIM에서도 같은 경향을 보였다. 그림 8은 해상도를 네 배 향상시켰을 때의 결과로 사용한 모델의 성능을 객관적으로 비교하기 위해 왼쪽에 바이큐빅 보간법으로 복원한 이미지를 추가하였다. 수치상으로 RCAN 모델이 더 좋은 성능을 보였다.




그림 7. 두 배 향상했을 때 비교(좌: 원본, 우: 초해상화 적용)




그림 8. 네 배 향상했을 때 비교(좌: 바이큐빅 보간법, 중: 원본, 우: 초해상화 적용)

	경우 5(x2)	경우 6(x4)	Bicubic(x4)
평균 PSNR	37.12	37.33	35.33
평균 SSIM	0.9794	0.9635	0.9456

표 3. 향상 배율별 성능 비교

4.3. 결과 분석

손실함수별 성능을 비교하기 위해 설계했던 경우1과 2, 경우3과 4를 비교하였을 때, 평균 PSNR, SSIM 값 모두 L1 손실함수가 MSE 손실함수보다 좋은 수치를 보였다(표2). MSE는 오차를 제공하기 때문에 단순히 절댓값만 취하는 L1보다 민감하게 작용하지만, 중간에 오차가 될 경우 MSE는 L1의 오차의 제곱만큼 증가하기 때문에 이를 회복하기 위해서는 L1보다 많은 훈련이 필요하다. 이번 연구에서도 그림 10과 그림 11과 같이 경우1과 2, 경우 3과 4 모두 훈련 초기에 오차가 튀었음에도 L1 일 때에는 금방 회복이 되어 훈련 마지막 단계에서는 오차가 1대로 끝났지만 MSE의 경우, 3으로 끝나는 모습을 보였다. 그 결과, 경우1과 2, 경우3과 4 모두에서 L1으로 훈련했을 때 MSE에 비해 좋은 성능을 보였다.




그림 9. 훈련 중 손실함수별 오차 그래프(좌: 경우1, 우: 경우2)




그림 10. 훈련 중 손실함수별 오차 그래프(좌: 경우3, 우: 경우4)

초해상화 기법의 적용 가능성을 보기 위해 설계했던 경우5와 6에서는 높은 수치의 PSNR과 SSIM이 나왔다(표 3). 해상도를 두 배 향상한 것이 네 배 향상했을 때에 비해 높은 PSNR과 SSIM이 나온 이유는 복원해야 하는 픽셀이 네 배 향상할 때에 비해 현저히 적고 복원하는데 필요한 픽셀의 정보도 네 배 향상할 때보다 많기 때문이다. 바이큐빅 보간법을 사용하여 복원한 결과와 연구 결과를 비교했을 때 평균 PSNR과 SSIM 모두 연구 결과에서 더 좋은 수치를 보였다. 시각적으로 비교했을 때 바이큐빅 보간법을 사용하여 복원한 것이 더 부드러워 보이지만 하얀 부분 사이에 보이는 검은 점과 같이 미세한 특징은 RCAN 모델을 사용한 결과에서 더 선명하기 때문에 높은 수치가 나온 것으로 보인다. 하지만 바이큐빅 보간법을 사용했을 때에도 높은 수치를 보이는데, 이는 시험에 사용한 입력 데이터의 구조가 단순하고 512x512임에도 넓은 부분을 나타내기 때문에 입력 데이터 자체도 선명하지 않아 보간법을 사용해도 충분히 복원되었기 때문이라고 생각된다. 그럼에도 불구하고 미세한 데이터도 중요한 천문학에서 연구의 정확성과 정밀성을 위해서 이번 연구에서 사용한 RCAN의 결과가 기존의 보간법을 사용하는 것보다 활용 가치가 높을 것이다.

5. 결론

천문학 연구에서 관측은 이론을 뒷받침할 수 있는 핵심적인 증거이므로 매우 중요한 부분을 차지한다. 지금보다 더 나아간 연구를 위해서는 더 정밀한 관측이 필요하다. 더 정밀한 관측은 새로운 망원경을 통해서도 이루어지지만 기존의 데이터를 더 향상시킨다면 금전적, 시간적인 이득을 모두 취할 수 있다. 이번 연구에서는 기존의 데이터를 향상시키는 방안으로 초해상화 기법을 적용하였고, 천문학 데이터의 적용 가능성과 어떤 손실함수를 사용해야 좋은 성능을 얻을 수 있는지 알아보았다. L1과 MSE 손실함수만을 사용하여 비교했을 때, 해상도를 두 배, 네 배 향상시키는 경우 모두에서 L1 손실함수에서 더 좋은 성능을 보였다. 현재 몇몇 연구에서는 지각 오차(Perceptual loss), SSIM 오차 등 다양한 손실함수를 사용한다. 이 손실함수들은 효율적으로 사진을 비교하기 위해 고안된 것으로 기존의 L1과 MSE 손실함수보다 좋은 성능을 낸다고 밝혀져 있는데 이러한 손실함수들이 초해상화 기법에서는 어떤 성능을 보이는지 추가적으로 비교할 필요가 있다.

연구에서는 히노데 위성의 해상도가 위성 관측 중에서 가장 높기 때문에 비교할 수 있는 데이터가 없었으므로 기존 사진의 해상도를 낮추어 다시 올리는 방식으로 진행하였다. 그 결과, RCAN을 사용하여 초해상화 기법을 적용한 경우, 단순히 바이큐빅 보간법을 사용했을 때보다 원본 사진과 더 유사하다는 것을 보였다. 하지만 처음 목표였던 기존 사진의 해상도를 높이기 위해서는 더 좋은 해상도의 비교 사진이 필요하다. 현재 구동 중인 망원경 중 히노데 위성보다 좋은 성능을 보이는 망원경은 지상의 Big Bear Solar Observatory(BBSO)의 New Solar Telescope(NST)이지만, 연구 데이터가 없었으므로 비교할 수는 없었다. 이번 연구에서 히노데 위성의 원본 사진의 해상도를 높였을 때 비교 대상이 없어 수치는 나타내지 못하지만 그림 9와 같은 결과가 나왔다. 이후에 히노데 위성과 BBSO가 함께 진행한 연구의 데이터를 사용할 수 있다면 이번 연구의 모델을 통해 해상도를 향상시킨 결과와 NST의 관측 사진을 비교할 수 있을 것이다. 그 결과가 좋다면, 지상관측으로서 기후의 영향으로 관측이 불가능할 수 있는 NST의 문제점을 상시 구동 중인 히노데 위성의 데이터를 향상 시킴으로써 극복할 수 있을 것이다.




그림 11. 원본의 해상도를 향상했을 때 사진

참고문헌

- [1] 우리 일상에 빠르게 자리잡고 있는 딥러닝(D.L)의 사례, <https://blog.skcc.com/3620>
- [2] Atlas, <https://www.bostondynamics.com/atlas>
- [3] SDO Instruments, <https://sdo.gsfc.nasa.gov/mission/instruments.php>
- [4] What is the differences between artificial neural network (computer science) and biological neural network?, <https://www.quora.com/What-is-the-differences-between-artificial-neural-network-computer-science-and-biological-neural-network>
- [5] Bee Lim, Sanghyun Son, Heewon Kim, Seungjun Nah & Kyoung Mu Lee, 'Enhanced Deep Residual Networks for Single Image Super-Resolution', 『CVPRW 2017』, IEEE, 2017.
- [6] Eunsu Park, Yong-Jae Moon, Seulki Shin, Kangwoo Yi, Daye Lim, Harim Lee & Gyungin Shin, 'Application of the Deep Convolutional Neural Network to the Forecast of Solar Flare Occurrence Using Full-disk Solar Magnetograms', 『The Astrophysical Journal』 Volume 869, The American Astronomical Society, 2018.
- [7] Chao Dong, Chen Change Loy, Kaiming He & Xiaoou Tang, 'Image Super-Resolution Using Deep Convolutional Networks', 『IEEE Transactions on Pattern Analysis and Machine Intelligence』 Volume 38, IEEE, 2016.
- [8] Christian Ledig, Lucas Theis, Ferenc Huszar, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang & Wenzhe Shi, 'Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network', 『CVPR 2017』, IEEE, 2017.
- [9] C.J. Diaz Baso & A. Asensio Ramos, 'Enhancing SDO/HMI images using deep learning', 『Astronomy & Astrophysics』 Volume 614, ESO, 2018.
- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren & Jian Sun, 'Deep Residual Learning for Image Recognition', 『CVPR 2016』, IEEE, 2015.
- [11] Karen Simonyan & Andrew Zisserman, 'Very Deep Convolutional Networks for Large-Scale Image Recognition', 『ICLR 2015』, ICLR, 2014.
- [12] Taeyoung Kim, Eunsu Park, Harim Lee, Yong-Jae Moon, Sung-Ho Bae, Daye Lim, Soojeong Jang, Lokwon Kim, Il-Hyun Cho, Myungjin Choi & Kyung-Suk Cho, 'Solar farside magnetograms from deep learning analysis of STEREO/EUVI data', 『Nature Astronomy』 3, 2019.
- [13] Yifan Wang, Federico Perazzi, Brian McWilliams, Alexander Sorkine-Hornung, Olga Sorkine-Hornung & Christopher Schroers, 'A Fully Progressive Approach to Single-Image Super-Resolution', 『CVPRW 2017』, IEEE, 2017.
- [14] Yulun Zhang, Kunpeng Li, Kai Li, Lichen Wang, Bineng Zhong & Yun Fu, 'Image Super-

Resolution Using Very Deep Residual Channel Attention Networks」, 『ECCV 2018』, ECCV, 2018.

- [15] Zhou Wang, A.C. Bovik, H.R. Sheikh & E.P. Simoncelli, 「Image quality assessment: from error visibility to structural similarity」, 『IEEE Transactions on Image Processing』 Volume 13, IEEE, 2004.